

Raport projektowy

**Opracowanie prototypu GraphRAG
wspomagającego wyszukiwanie powiązań
pomiędzy obiektami i zdarzeniami
występującymi w artykułach prasowych**

Miłosz Słowiński
Piotr Karamon

25 czerwca 2026

Spis treści

1	Klasyczny RAG i jego ograniczenia	2
1.1	Jak działa zwykły RAG	2
1.2	Kiedy to wystarcza	2
1.3	Gdzie zawodzi	2
1.4	Pomysł grafu wiedzy	3
2	GraphRAG firmy Microsoft	3
2.1	Faza 1: indeksowanie	4
2.1.1	Podział na fragmenty	4
2.1.2	Ekstrakcja encji i relacji	4
2.1.3	Budowa grafu wiedzy	5
2.1.4	Wykrywanie społeczności	5
2.1.5	Podsumowania społeczności	5
2.1.6	Osadzenia wektorowe	5
2.2	Faza 2: tryby zapytań	5
2.2.1	Wyszukiwanie lokalne	6
2.2.2	Wyszukiwanie globalne	6
2.2.3	Wyszukiwanie DRIFT	7
2.3	Wyniki z pracy	7
2.4	Ograniczenia	7
3	LightRAG	7
3.1	Indeksowanie	7
3.1.1	Aktualizacja przyrostowa	8
3.2	Dwupoziomowe wyszukiwanie	8
3.3	Porównanie z GraphRAG	9
4	Podsumowanie	10
A	Korpus użyty w projekcie	10

1 Klasyczny RAG i jego ograniczenia

1.1 Jak działa zwykły RAG

RAG (*retrieval-augmented generation*, czyli generowanie wspomagane wyszukiwaniem) to technika, w której model językowy dostaje dodatkową wiedzę z zewnętrznego źródła. Sam model zna tylko to, czego nauczył się podczas treningu, i ma ograniczone okno kontekstu, więc nie da się wkleić do niego całej bazy dokumentów. Zamiast tego do modelu trafiają tylko niewielkie, dobrze dobrane fragmenty tekstu, które powinny zawierać odpowiedź.

W najpopularniejszym wariantcie, nazywanym tu RAG wektorowym, działa to następująco:

1. Dokumenty dzielone są na krótkie fragmenty.
2. Każdy fragment zamieniany jest na wektor liczb (tak zwane osadzenie), który oddaje jego znaczenie. Wektory trafiają do bazy wektorowej.
3. Pytanie użytkownika również zamieniane jest na wektor.
4. System wybiera k fragmentów najbardziej podobnych do pytania (zwykle przez podobieństwo kosinusowe wektorów).
5. Te fragmenty trafiają do okna kontekstu modelu, który na ich podstawie formułuje odpowiedź.

Całe podejście opiera się więc na jednej operacji: znajdź teksty podobne do pytania.

1.2 Kiedy to wystarcza

RAG wektorowy sprawdza się dobrze, gdy odpowiedź mieści się w jednym albo kilku fragmentach tekstu i gdy pytanie jest podobne do tego fragmentu pod względem słów lub znaczenia. Dobrze pasują tu proste pytania o fakty, na przykład „kiedy odbył się szczyt energetyczny w Warszawie?” albo „gdzie miała miejsce powódź?”. W takich przypadkach zwykle istnieje konkretny fragment tekstu, który wprost zawiera odpowiedź, a zadaniem systemu jest po prostu go odnaleźć.

1.3 Gdzie zawodzi

Problem pojawia się przy pytaniach, które wymagają zrozumienia powiązań między elementami rozrzuconymi po wielu dokumentach. Można je z grubsza podzielić na dwa rodzaje:

- Pytania relacyjne, na przykład „co łączy Marię Nowak z firmą GreenGrid Europe?” albo „kto brał udział w tym samym wydarzeniu co Amber Analytics?”.
- Pytania o sens całości, na przykład „jakie główne wątki przewijają się przez wszystkie te artykuły?” albo „które zdarzenia łączą się przez tych samych uczestników?”.


W obu przypadkach nie istnieje pojedynczy fragment, który zawierałby gotową odpowiedź. Odpowiedź trzeba złożyć z wielu artykułów, często łącząc fakty, które nigdy nie pojawiają się razem w jednym fragmencie. Tu RAG wektorowy ma fundamentalne ograniczenie. Indeks wektorowy przechowuje listę fragmentów i potrafi mierzyć ich podobieństwo, ale sama taka struktura nie jest w stanie naturalnie oddać powiązań między obiektami opisanymi w korpusie. Dwa artykuły, które wspominają tę samą osobę, są w takim indeksie zupełnie niepowiązane, jeśli używają różnych słów. System może co najwyżej liczyć, że oba fragmenty naraz okażą się podobne do pytania i trafią do kontekstu, co przy większej liczbie powiązań przestaje działać.

1.4 Pomysł grafu wiedzy

Systemy grafowe rozwiązują ten problem, zmieniając to, co przechowuje indeks. Zamiast samej listy fragmentów budują graf wiedzy, w którym:

- węzłami są encje, to znaczy konkretne osoby, organizacje, miejsca i zdarzenia,
- krawędziami są relacje między nimi, na przykład „uczestniczy w”, „dostarcza”, „odbywa się w”.

Kluczowa zmiana polega na tym, że relacja staje się pełnoprawnym elementem indeksu, a nie czymś, co trzeba dopiero odgadnąć z tekstu w trakcie zapytania. Jeśli Maria Nowak pojawia się w pięciu artykułach, w grafie odpowiada jej jeden węzeł, do którego prowadzą krawędzie ze wszystkich tych artykułów. Dzięki temu, żeby odpowiedzieć na pytanie o powiązania, system nie musi mieć szczęścia przy doborze podobnych fragmentów. Może po prostu przejść po krawędziach grafu i odczytać, co i z czym jest połączone. Rysunek 1 zestawia oba podejścia.




Rysunek 1: Klasyczny RAG wyszukuje fragmenty tekstu podobne do pytania. RAG grafowy buduje z tych samych dokumentów graf wiedzy i odpowiada, przechodząc po jego węzłach i krawędziach albo korzystając z gotowych podsumowań całych powiązanych ze sobą grup obiektów.

To samo widać dobrze na przykładzie naszego korpusu artykułów prasowych. Rysunek 2 pokazuje uproszczony wycinek grafu wiedzy zbudowanego z wiadomości o bałtyckiej sieci energetycznej i o powodzi w Krakowie (korpus opisany jest dokładniej w dodatku A). Widać tam powiązania, których żaden pojedynczy artykuł nie zawiera w całości. Na przykład firma Amber Analytics dostarcza czujniki do projektu Baltic Grid Agreement, a jednocześnie drony użyte przy akcji powodziowej w Krakowie. Podobnie Maria Nowak pojawia się i na szczycie energetycznym, i przy reakcji na powódź. To są dokładnie te mosty między wątkami, które wyszukiwanie po podobieństwie tekstu gubi, a które w grafie są po prostu krawędziami.

2 GraphRAG firmy Microsoft

GraphRAG opisany przez Edge i współpracowników [1] powstał, by rozwiązać konkretny problem, z którym klasyczny RAG sobie nie radzi: globalne rozumienie całego zbioru dokumentów. Chodzi



Rysunek 2: Uproszczony przykład grafu wiedzy zbudowanego z naszego korpusu artykułów. Węzły to obiekty różnych typów, krawędzie to nazwane relacje. Linie przerywane wyróżniają powiązania, które łączą oddzielne wątki (energetyczny i powodziowy) i których nie znajdziemy w żadnym pojedynczym artykule.

o pytania w stylu „jakie są główne wątki w tych materiałach?”, na które nie ma jednego najlepszego fragmentu, bo odpowiedź wymaga streszczenia całości. Autorzy nazywają to zadaniem podsumowania ukierunkowanego pytaniem.

System działa w dwóch fazach. Najpierw, raz, buduje indeks z dokumentów. Potem korzysta z tego indeksu przy każdym zapytaniu. Warto je rozdzielić, bo to właśnie kosztowna faza indeksowania odróżnia GraphRAG od prostszego RAG.

2.1 Faza 1: indeksowanie

Budowa indeksu przebiega w kilku krokach, od surowego tekstu do gotowych podsumowań.

2.1.1 Podział na fragmenty

Dokumenty dzielone są na zachodzące na siebie fragmenty (w pracy domyślnie 600 tokenów ze 100-tokenowym zakładem). Rozmiar fragmentu to istotny wybór projektowy. Dłuższe fragmenty oznaczają mniej wywołań modelu podczas ekstrakcji, ale model gorzej wychwytyuje informacje pojawiające się pod koniec długiego fragmentu.

2.1.2 Ekstrakcja encji i relacji

Dla każdego fragmentu model językowy jest proszony o wypisanie:

- encji, czyli nazwanych osób, organizacji, miejsc i zdarzeń, razem z krótkim opisem,
- relacji, czyli skierowanych powiązań między parami encji, każdej z opisem,
- faktów, czyli krótkich, weryfikowalnych stwierdzeń o encjach, na przykład dat i ról.

Prompt można dopasować do dziedziny, dodając przykłady charakterystyczne dla nauki, prawa czy medycyny. Ten krok jest sercem indeksowania i zarazem jego głównym kosztem, bo model trzeba wywołać osobno dla każdego fragmentu.

2.1.3 Budowa grafu wiedzy

Wszystkie wydobyte encje i relacje łączone są w jeden skierowany graf. Ta sama encja często pojawia się w wielu fragmentach, więc jej wystąpienia są scalane, a opisy podsumowywane przez model. Powtarzające się relacje również są łączone, a waga krawędzi odpowiada temu, jak często dana relacja występowała w tekście. W podstawowej wersji dopasowanie nazw odbywa się przez dokładne porównanie napisów, choć możliwe jest też łagodniejsze dopasowanie.

2.1.4 Wykrywanie społeczności

To krok, który najmocniej odróżnia GraphRAG od innych podejść grafowych. Na gotowym grafie uruchamiany jest algorytm wykrywania społeczności *Leiden* [3]. Dzieli on graf na grupy gęsto powiązanych encji, na przykład wszystkie wątki wokół jednego szczytu albo wszystkich uczestników jednej afery. Co ważne, robi to hierarchicznie i na wielu poziomach:

- poziom C0 to najszersze, najbardziej ogólne społeczności (jest ich najmniej),
- poziomy C1, C2, C3 to coraz drobniejsze podspołeczności.

Każdy poziom pokrywa cały graf w sposób rozłączny i kompletny, więc daje inną „rozdzielczość” spojrzenia na zbiór. Rysunek 3 pokazuje tę ideę.

2.1.5 Podsumowania społeczności


Dla każdej społeczności, na każdym poziomie, model generuje opisowe podsumowanie w języku naturalnym. Podsumowania najniższego poziomu powstają z opisów encji, relacji i faktów. Podsumowania wyższych poziomów powstają z podsumowań ich podspołeczności, oddolnie. W efekcie powstaje bogaty, hierarchiczny zbiór gotowych streszczeń, które obejmują cały korpus jeszcze zanim padnie jakiegokolwiek pytanie. To te streszczenia pozwalają później odpowiadać na pytania o całość bez czytania wszystkich fragmentów na nowo.

2.1.6 Osadzenia wektorowe

Warto w tym miejscu rozwiązać częste nieporozumienie. GraphRAG nie rezygnuje z klasycznych osadzeń wektorowych, tych samych, na których opiera się zwykły RAG. Oprócz grafu i podsumowań system liczy na etapie indeksowania osadzenia dla opisów encji oraz dla podsumowań społeczności i zapisuje je w bazie wektorowej. Pełnią one jednak rolę pomocniczą, a nie główną. Służą do tego, żeby przy zapytaniu szybko dopasować pytanie do właściwych encji albo podsumowań, czyli znaleźć dobry punkt startowy w grafie. Sama odpowiedź powstaje już z treści grafu i streszczeń, a nie z surowych fragmentów wybranych po podobieństwie. Z tych osadzeń korzysta wyszukiwanie lokalne oraz DRIFT.

2.2 Faza 2: tryby zapytań

GraphRAG udostępnia kilka trybów odpowiadania, które korzystają z gotowego indeksu na zupełnie różne sposoby. Tryb wybiera się dla każdego pytania osobno.



Rysunek 3: Wykrywanie społeczności dzieli graf na grupy gęsto powiązanych encji (po lewej), a robi to na wielu poziomach jednocześnie (po prawej). Dla każdej społeczności na każdym poziomie model generuje osobne podsumowanie. Poziom C0 daje najszersze spojrzenie, niższe poziomy coraz drobniejsze.

2.2.1 Wyszukiwanie lokalne

Wyszukiwanie lokalne służy do pytań, które wskazują konkretną encję, na przykład „co zrobiła firma GreenGrid Europe?”. System zamienia pytanie na wektor i porównuje je z policzonymi wcześniej osadzeniami opisów encji, żeby znaleźć węzły startowe. Jest to więc dokładnie ten sam mechanizm, co w zwykłym RAG, tyle że tu szuka się pasujących encji, a nie pasujących fragmentów tekstu. Następnie system zbiera wokół nich kontekst z kilku źródeł naraz: fragmenty tekstu wspominające te encje, podsumowania społeczności, do których encje należą, sąsiednie encje w grafie, krawędzie wychodzące z węzłów startowych oraz związane z nimi fakty. To wszystko jest porządkowane według trafności, upakowywane w jedno okno kontekstu i przekazywane do modelu, który jednym wywołaniem tworzy odpowiedź. Lokalne wyszukiwanie jest więc tanie, bo ogranicza się do najbliższego otoczenia wskazanych encji.

2.2.2 Wyszukiwanie globalne

Wyszukiwanie globalne odpowiada na pytania bez konkretnej kotwicy, które dotyczą całego korpusu. Co istotne, ten tryb w ogóle nie sięga do grafu w trakcie zapytania i nie korzysta z osadzeń wektorowych. Działa wyłącznie na wcześniej przygotowanych podsumowaniach społeczności, w schemacie map-reduce:

1. Wybierany jest poziom społeczności (na przykład C0 albo C2) i pobierane są wszystkie podsumowania z tego poziomu.
2. Podsumowania są tasowane (żeby uniknąć faworyzowania początku kontekstu) i dzielone na porcje mieszczące się w oknie modelu.
3. Krok *map*: każda porcja trafia osobno do modelu, który wypisuje listę krótkich stwierdzeń istotnych dla pytania, każde z oceną ważności od 0 do 100. Wszystkie porcje przetwarzane są równolegle.
4. Stwierdzenia z oceną 0 są odrzucane.
5. Krok *reduce*: pozostałe stwierdzenia są sortowane według ważności, pakowane w nowe okno kontekstu i jednym końcowym wywołaniem model składa z nich globalną odpowiedź.

To podejście jest skuteczne, ale kosztowne, bo w kroku *map* liczba wywołań modelu rośnie wraz z liczbą społeczności na wybranym poziomie. Na największym zbiorze z pracy poziom

drobny oznacza setki wywołań na jedno pytanie, podczas gdy poziom C0 wystarcza zaledwie kilkudziesięciu wywołaniom przy umiarkowanym spadku jakości.

2.2.3 Wyszukiwanie DRIFT

Istnieje też tryb pośredni, DRIFT, który zaczyna od kontekstu globalnego (podsumowań społeczności), a potem iteracyjnie schodzi w głąb grafu poprzez wyszukiwanie lokalne, zadając kolejne pytania pomocnicze i pogłębiając te wątki, w których jest najbardziej pewny. Łączy więc szerokie spojrzenie z lokalną dokładnością.

2.3 Wyniki z pracy

Autorzy porównali GraphRAG z klasycznym RAG wektorowym na dwóch dużych korpusach (transkrypcje podcastów i artykuły prasowe, każdy rzędu miliona tokenów), używając modelu jako sędziego oceniającego odpowiedzi. GraphRAG na wszystkich poziomach społeczności wyraźnie wygrywał pod względem kompletności i różnorodności odpowiedzi, z przewagą rzędu 72–83% i 62–82%. Co ważne, podsumowania na poziomie C0 osiągały ten wynik, zużywając około 97% mniej tokenów niż streszczanie wprost z tekstu źródłowego.

2.4 Ograniczenia

GraphRAG płaci za swoją skuteczność wysoką ceną, którą warto wyraźnie nazwać, bo to ona motywuje powstanie lżejszych systemów takich jak LightRAG.

- **Kosztowne indeksowanie.** Model trzeba wywołać dla każdego fragmentu przy ekstrakcji, a potem jeszcze raz dla każdej społeczności na każdym poziomie przy generowaniu podsumowań. To przekłada się na bardzo dużo wywołań i tokenów, a w pracy zbudowanie indeksu zajmowało rzędu kilku godzin.
- **Drogie zapytania globalne.** Schemat map-reduce wykonuje osobne wywołanie modelu na społeczność, więc na większych zbiorach jedno pytanie globalne to setki wywołań.
- **Trudna aktualizacja.** To może być najpoważniejsze ograniczenie w praktyce. Dodanie nowych artykułów zmienia strukturę grafu, więc trzeba na nowo wykryć społeczności i wygenerować dotknięte podsumowania. Przy strumieniu napływających wiadomości oznacza to ciągle, kosztowne przebudowywanie indeksu.

3 LightRAG

LightRAG [2] to system zaprojektowany wprost po to, by usunąć dwa największe koszty GraphRAG opisane wyżej: drogie zapytania i kosztowną aktualizację indeksu. Najkrócej: LightRAG rezygnuje z hierarchii społeczności i z generowania ich podsumowań, a w zamian wprowadza dwupoziomowe wyszukiwanie po grafie wzbogaconym o bazę wektorową.

3.1 Indeksowanie

LightRAG buduje graf wiedzy podobnie jak GraphRAG, w trzech operacjach na każdym fragmencie:

- **Ekstrakcja.** Model wydobywa encje i relacje z fragmentu, tak jak w GraphRAG.
- **Profilowanie do par klucz-wartość.** Tu pojawia się główna różnica. Każdy węzeł i każda krawędź zamieniane są na parę (K, V) . Klucz K to słowo lub krótka fraza służąca do wyszukiwania, a wartość V to wygenerowany przez model akapit opisujący daną encję lub relację wraz z istotnymi fragmentami źródła. Encja ma jeden klucz, którym jest jej nazwa. Relacja może mieć kilka kluczy, bo są nimi ogólniejsze frazy tematyczne opisujące, czego dotyczy powiązanie, na przykład „współpraca energetyczna” czy „nadzór regulacyjny”.
- **Deduplikacja.** Identyczne encje i relacje z różnych fragmentów są scalane, żeby graf pozostał zwarty.

Najważniejsze, czego tu nie ma: nie ma wykrywania społeczności ani generowania ich podsumowań. To właśnie ten krok był w GraphRAG najdroższy i najtrudniejszy w aktualizacji. Klucze K zapisywane są jako wektory w bazie wektorowej, więc do encji i relacji można potem docierać przez podobieństwo, podobnie jak do fragmentów w klasycznym RAG, tyle że tu obiektem wyszukiwania jest struktura grafu, a nie surowy tekst.

3.1.1 Aktualizacja przyrostowa

Nowy dokument przechodzi przez te same trzy operacje, a powstałe węzły i krawędzie są po prostu dołączane do istniejącego grafu jako suma zbiorów. Nie trzeba przebudowywać żadnej struktury społeczności, bo jej nie ma. To bezpośrednie rozwiązanie problemu, który w GraphRAG wymagał kosztownego przeliczania podsumowań przy każdej zmianie danych. Dla zbioru artykułów, który stale rośnie, jest to istotna różnica praktyczna.

3.2 Dwupoziomowe wyszukiwanie

Pomysł polega na tym, że pytania bywają dwojakiego rodzaju, więc i wyszukiwanie ma dwa poziomy:

- poziom niski dotyczy konkretnych encji i ich atrybutów, na przykład „kim jest Maria Nowak?”,
- poziom wysoki dotyczy szerszych tematów i powiązań, na przykład „jak współpraca energetyczna wpływa na region?”.

Samo wyszukiwanie wygląda następująco:

1. **Wydobycie słów kluczowych (jedno wywołanie modelu).** Pytanie trafia do modelu, który wypisuje dwie listy: słowa lokalne (nazwy konkretnych encji) oraz słowa globalne (frazy tematyczne opisujące, o co w pytaniu chodzi).
2. **Dopasowanie niskiego poziomu.** Słowa lokalne są porównywane z kluczami encji w bazie wektorowej, co zwraca wartości V pasujących encji.
3. **Dopasowanie wysokiego poziomu.** Słowa globalne są porównywane z kluczami tematycznymi relacji, co zwraca wartości V pasujących powiązań.
4. **Rozszerzenie o sąsiadów.** Dla dopasowanych encji i relacji dołączani są ich bezpośredni sąsiedzi w grafie (sąsiedzi w odległości jednej krawędzi). Dzięki temu w kontekście pojawiają się też encje, których nazwa nie padła w pytaniu, ale które są powiązane z tymi, które padły.

5. **Złożenie kontekstu i odpowiedź (jedno wywołanie modelu).** Wszystkie zebrane wartości V są łączone i przekazywane modelowi razem z pytaniem, a model jednym wywołaniem tworzy odpowiedź.

W trybie hybrydowym, który jest zalecanym domyślnym ustawieniem, kroki dopasowania niskiego i wysokiego poziomu działają jednocześnie, więc system obsługuje zarówno pytania o konkretne encje, jak i o ogólne tematy. Kluczowa obserwacja kosztowa jest taka, że całe wyszukiwanie mieści się w zaledwie dwóch wywołaniach modelu, niezależnie od wielkości korpusu: jedno na wydobycie słów kluczowych i jedno na odpowiedź. Nie ma tu przechodzenia po setkach społeczności, bo społeczności w ogóle nie istnieją.

Ciekawym wynikiem pracy jest test, w którym z wartości V usunięto oryginalny tekst źródłowy, zostawiając tylko streszczenia wygenerowane przez model. Jakość odpowiedzi nie spadła, a w części dziedzin nawet wzrosła. Oznacza to, że uporządkowane streszczenia encji i relacji potrafią nieść wystarczająco dużo informacji by zastąpić surowy tekst.

3.3 Porównanie z GraphRAG

LightRAG i GraphRAG dzielą tę samą podstawową intuicję, że strukturę powiązań warto zapisać wprost przy budowie indeksu. Różnią się tym, co robią dalej. GraphRAG dokłada hierarchię społeczności i ich podsumowania, co świetnie służy pytaniom o sens całości, ale jest drogie i trudne w aktualizacji. LightRAG rezygnuje ze społeczności na rzecz dwupoziomowego wyszukiwania po parach klucz-wartość, co daje stały, niski koszt zapytania i tanie aktualizacje. Tabela 1 zbiera te różnice.

Aspekt	GraphRAG (Microsoft)	LightRAG
Główny pomysł	hierarchia społeczności i podsumowania, odpowiedź metodą map-reduce	płaski graf encji i relacji, odpowiedź przez dwupoziomowe wyszukiwanie
Struktura grafu	graf wiedzy z wielopoziomową hierarchią społeczności	graf wiedzy z bazą wektorową par klucz-wartość
Wywołania modelu przy zapytaniu	rośnie z liczbą społeczności (setki dla dużych zbiorów)	stałe, dwa wywołania niezależnie od wielkości korpusu
Aktualizacja danych	wymaga ponownego wykrycia społeczności i podsumowań	dołączenie nowych węzłów i krawędzi, prawie bez kosztu
Najlepszy typ pytań	globalne pytania o sens całości	zarówno konkretne, jak i tematyczne pytania o powiązania
Słaby punkt	wysoki koszt i trudna aktualizacja	słabszy w czysto globalnym streszczaniu niż podsumowania społeczności

Tabela 1: Zestawienie GraphRAG i LightRAG na najważniejszych wymiarach.

W eksperymentach na czterech dziedzinach LightRAG wypadł lepiej od wszystkich porównywanych podejść, w tym od GraphRAG, jednocześnie będąc znacznie tańszym przy zapytaniach. Różnica w koszcie jest wyraźna: na największym zbiorze jedno zapytanie w GraphRAG zużywało setki tysięcy tokenów i setki wywołań modelu, podczas gdy w LightRAG było to mniej niż sto tokenów i pojedyncze wywołanie wyszukiwania. To pokazuje, że rezygnacja ze społeczności

nie musi oznaczać gorszych odpowiedzi, a daje duże oszczędności tam, gdzie dane często się zmieniają.

4 Podsumowanie

Klasyczny RAG opiera się na jednej operacji, czyli na wyszukiwaniu tekstów podobnych do pytania. Dla prostych pytań o fakty to w zupełności wystarcza i nie ma powodu sięgać po nic więcej. Trudność zaczyna się przy pytaniach o powiązania i o sens całości, bo taki indeks nie oddaje wprost powiązań między obiektami i potrafi je odtworzyć tylko przypadkiem.

Systemy GraphRAG rozwiązują to, zapisując encje i relacje wprost w grafie wiedzy już na etapie indeksowania. GraphRAG firmy Microsoft idzie krok dalej i buduje hierarchię społeczności wraz z gotowymi podsumowaniami, dzięki czemu potrafi odpowiadać na pytania o całość korpusu. Płaci za to wysokim kosztem indeksowania, drogimi zapytaniami globalnymi i trudną aktualizacją przy nowych danych. LightRAG zachowuje sam graf, ale rezygnuje ze społeczności na rzecz dwupoziomowego wyszukiwania po parach klucz-wartość. Dzięki temu utrzymuje stały, niski koszt zapytania i pozwala tanio dokładać nowe dokumenty, co jest istotne dla stale rosnącego zbioru artykułów prasowych.

Wybór między tymi podejściami zależy więc od zastosowania. Tam, gdzie najważniejsze są globalne streszczenia dużego, w miarę stałego korpusu, naturalnie pasuje GraphRAG. Tam, gdzie dane często się zmieniają, a pytania mieszają konkretne encje z ogólnymi tematami, lepiej sprawdza się LightRAG. Klasyczny RAG pozostaje rozsądnym, tanim punktem odniesienia dla prostych pytań. Te obserwacje stanowią tło dla naszych własnych eksperymentów na korpusie artykułów, które opiszemy w kolejnej części dokumentacji.

A Korpus użyty w projekcie

Do testów i przykładów w tym raporcie wykorzystujemy niewielki, ale spójny korpus wiadomości prasowych. Składa się on z 18 artykułów, oznaczonych jako materiał syntetyczny i opatrzonych datami z okresu od kwietnia do maja 2026 roku. Artykuły zostały przygotowane tak, aby tworzyły jedną, powiązaną historię, a nie zbiór niezależnych tekstów.

Korpus spleta dwa wątki:

- wątek energetyczny wokół projektu rozbudowy bałtyckiej sieci energetycznej (Baltic Grid Agreement), szczytu w Warszawie, morskich farm wiatrowych pod Gdańskiem oraz magazynów energii,
- wątek kryzysowy wokół powodzi w Krakowie i akcji ratunkowej prowadzonej przez krajowe służby.

Najważniejszą cechą korpusu jest to, że te same obiekty powracają w wielu artykułach i łączą oba wątki. Na przykład firma Amber Analytics dostarcza czujniki do projektu energetycznego, a zarazem drony wykorzystane podczas powodzi, zaś Maria Nowak występuje i na szczycie energetycznym, i przy reakcji na kryzys. Dzięki temu korpus zawiera realne powiązania wielokrotowe, których nie da się odczytać z pojedynczego artykułu, co czyni go dobrym materiałem do porównania wyszukiwania klasycznego z grafowym.

W korpusie występują obiekty czterech głównych typów:

- osoby, na przykład Maria Nowak, Jonas Berg, Ewa Lewandowska,

- organizacje, na przykład GreenGrid Europe, NordicGrid, Amber Analytics, Clear Air Forum,
- zdarzenia, na przykład Baltic Grid Agreement, szczyt energetyczny w Warszawie, powódź w Krakowie,
- lokalizacje, na przykład Warszawa, Gdańsk, Wilno, Kraków.

Do korpusu dołączony jest zestaw 18 pytań w stylu śledczym, na przykład „co łączy Marię Nowak z firmą GreenGrid Europe?”, z których każde ma przypisaną oczekiwaną odpowiedź. Służą one do oceny poszczególnych trybów wyszukiwania.

Literatura

- [1] Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., Metropolitansky, D., Ness, R. O., Larson, J. (2024). *From Local to Global: A GraphRAG Approach to Query-Focused Summarization*. arXiv:2404.16130.
- [2] Guo, Z., Xia, L., Yu, Y., Ao, T., Huang, C. (2024). *LightRAG: Simple and Fast Retrieval-Augmented Generation*. arXiv:2410.05779.
- [3] Traag, V. A., Waltman, L., van Eck, N. J. (2019). *From Louvain to Leiden: guaranteeing well-connected communities*. Scientific Reports, 9, 5233.